

# 第二章 进程管理

重点

- 第一节 前趋图和程序执行
- 第二节 进程的描述
- 第三节 进程控制
- 第四节 进程同步
- 第五节 经典进程的同步问题
- 第六节 进程通信
- 第七节 线程

# 第一节 前趋图和程序执行

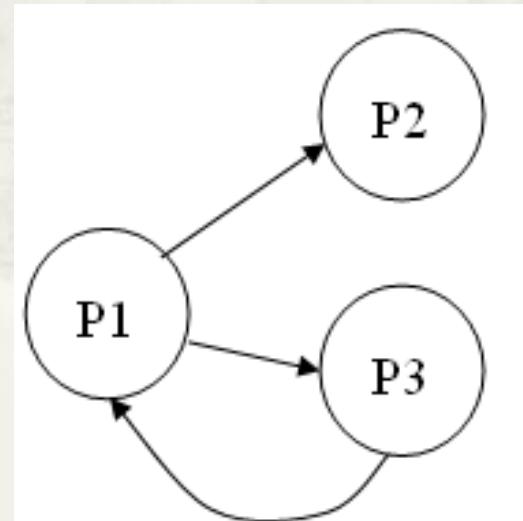
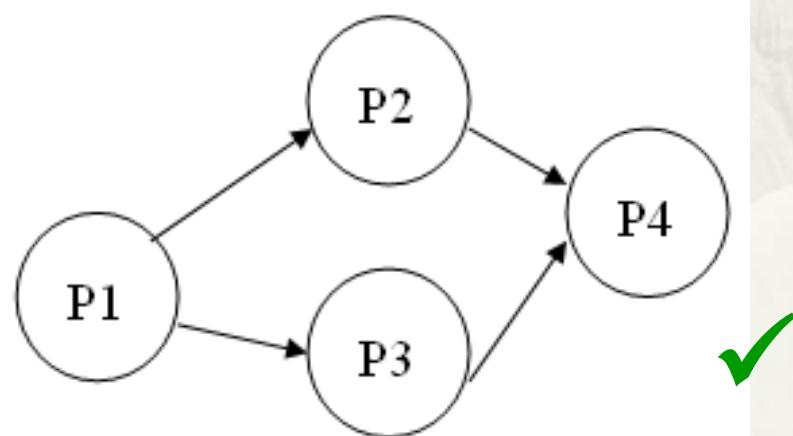
- 前趋图
- 程序顺序执行
- 程序并发执行

- **单道程序系统中，程序是顺序执行的：**  
必须在一个程序执行完后，才允许另一个程序执行
- **多道程序系统中，多个程序并发执行：**  
允许暂停一个程序的执行，而转去执行另一个程序
- 程序的这两种执行方式间有着显著的不同

# 前趋图

## \* 前趋图：有向无环图 (DAG)

- **作用：**描述进程间执行的先后顺序。
- **结点：**一个进程/程序段，或一条语句
- **有向边：**结点之间的前趋(偏序)关系



# 程序顺序执行

## 程序顺序执行的特征：

- **顺序性**

每一个操作必须在下一个操作开始之前结束

- **封闭性**

程序运行时独占全机资源，资源的状态只有本程序才能改变

- **可再现性**

只要初始条件和运行环境相同，当程序重复执行时，都将获得相同的结果。

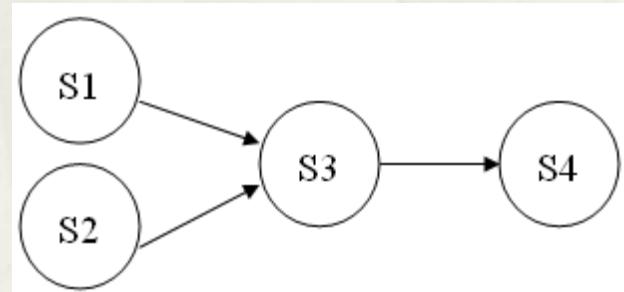
# 前趋图的例子：

S1:  $a = x + 2;$

S2:  $b = y + 4;$

S3:  $c = a + b;$

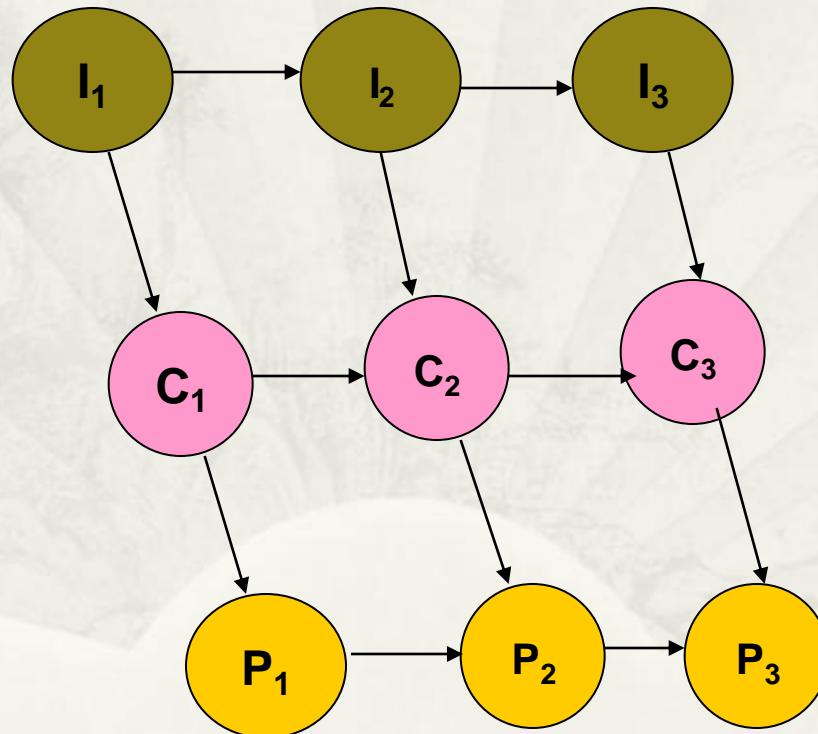
S4:  $d = c + b;$



# 程序并发执行

## ■ 并发执行时的前趋图

◆ 有三个程序： I=输入， C=计算， P=打印



## ● 并发执行时的特征

- 间断性：“停停走走”
- 失去封闭性：因为多个程序共享资源
- 不可再现性

例如：有两个循环程序A和B，共享一个变量n。程序A每执行一次时，都要做 $n=n+1$ ；程序B每执行一次时，都要执行Print(n)；然后将n置成0。程序A和B并发执行时，可能出现的情况如下：

- 1、 $n=n+1$ 在print(n)和 $n=0$ 之前，得到的n值为n+1,n+1,0
- 2、 $n=n+1$ 在print(n)和 $n=0$ 之后，得到的n值为n,0,1
- 3、 $n=n+1$ 在print(n)和 $n=0$ 之间，得到的n值为n,n+1,0

# 程序顺序执行与并发执行的比较

	顺序执行	并发执行
执行过程	顺序执行	交替执行
封闭性	独占资源 有封闭性	共享资源 无封闭性
可再现性	√	✗
程序间关系	无关系	间接制约或直接制约

- 多道程序系统中，程序并发执行，会失去封闭性，出现不可再现性，导致程序执行可能出现错误。
- 所以，通常意义下的程序不能参与并发执行。

## 第二节 进程的描述

---

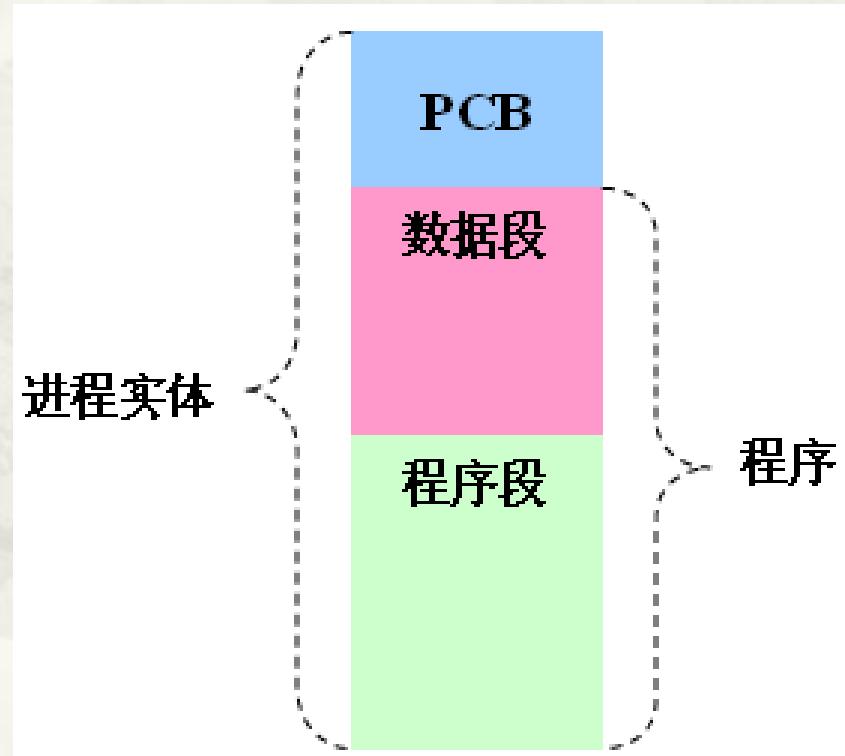
- 进程的定义和特征
- 进程的基本状态
- 进程的挂起状态
- 进程管理中的数据结构

# 进程的定义和特征

- 为使程序能**正确地并发**执行，且对并发执行进行描述和控制。
- 以“**程序**”为基础，又引入“**进程**”这一新的概念。

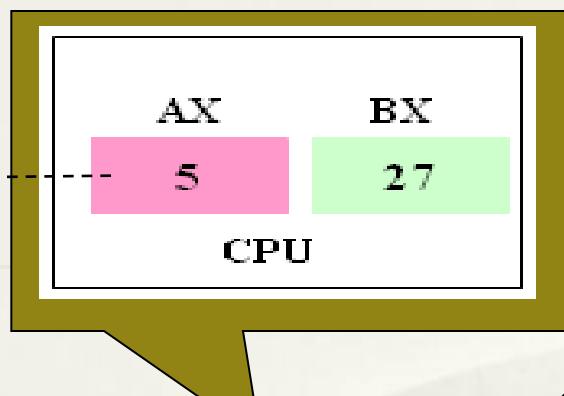
# 进程的结构特征

进程实体 = 程序 + 进程控制块(PCB)



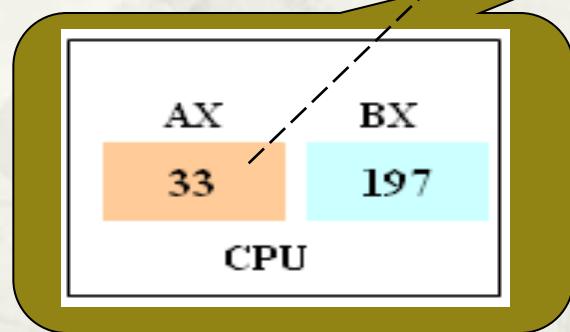
# Windows 中的进程





进程A —————  
进程B —————

后寄存器的状态

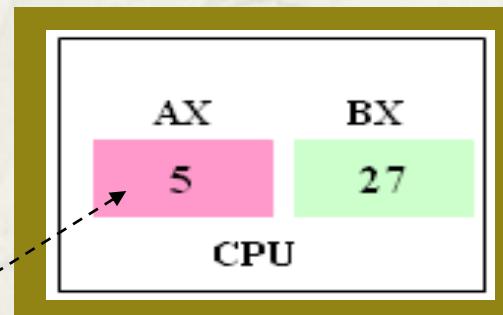


进程B执行完后寄存器的状态

暂存进程A执行完时  
寄存器的状态



恢复进程A上次执行完时  
寄存器的状态



# 进程控制块

- PCB(Process Control Block)
  - 记录了OS用于描述进程的当前情况以及控制进程运行的全部信息。
  - **进程存在的唯一标志。**
  - **作用：**使一个在多道程序系统中不能独立运行的程序，成为一个能独立运行且能并发执行的进程。
  - **位置：** OS中专门开辟的PCB区内

## ● PCB中的信息

- ① 进程标识符：唯一地标识一个进程

内部标识（OS）

外部标识（由创建者提供，由字母数字组成）

- ② 处理机状态

- ③ 进程调度信息

- ④ 进程控制信息

# Unix/Linux下的进程标识符是什么样的？

ps -ef

kill -9 12189



PID	COMMAND	%CPU	TIME	#TH	#PRTS	#IREGS	RPRVT	RSHRD	RSIZE	VSIZE
12189	httpd	0.0%	0:00.00	1	11	84	92K	2.28M	492K	31.9M
12188	top	14.7%	0:03.71	1	19	22	592K	344K	1.01M	27.0M
12186	httpd	0.0%	0:00.11	1	12	85	1.12M	2.25M	2.55M	31.9M
12184	Vienna	1.7%	0:21.90	6	127	242	50.2M+	9.97M+	55.9M+	198M+
12182	mdimport	0.0%	0:00.62	4	62	54	956K	1.98M	3.55M	39.3M
12176	ImageWell	0.0%	0:22.27	4	105	222	24.6M	7.45M	28.1M	198M
12136	bash	0.0%	0:00.07	1	14	17	132K	728K	596K	27.2M
12135	login	0.0%	0:00.03	1	16	37	0K	260K	1.34M	26.9M
12133	Terminal	0.9%	0:12.74	4	95	148	1.41M	7.34M	19.0M	143M
12131	Microsoft	0.0%	0:04.91	2	66	115	520K	3.40M	1.77M	131M
12128	Microsoft	1.7%	6:39.41	7	117	473	15.1M	13.5M	15.3M	239M
9665	Adium	0.8%	4:23.24	9	347	450	13.0M	9.84M	17.6M	212M
272	InstantSho	3.2%	0:03.21	2	154	181	1.87M	17.3M	15.0M	159M
267	Safari	0.4%	12:24.84	10	203	1523	105M	15.6M	69.2M	425M
266	cupsd	0.0%	0:00.20	2	30	26	40K	540K	848K	27.8M
237	iStat	5.4%	50:08.89	6	989	188	4.23M	6.31M	8.33M	155M

# \* Windows下的进程标识符是什么样的？



外部标识符

Windows 任务管理器

文件(F) 选项(O) 查看(V) 关机(U) 帮助(H)

应用程序 进程 性能 联网 用户

映像名称	用户名	CPU	内存使用
360tray.exe	Administrator	00	1,916 K
alg.exe	LOCAL SERVICE	00	3,828 K
csrss.exe	SYSTEM	00	15,512 K
ctfmon.exe	Administrator	00	3,664 K
daemon.exe	Administrator	00	4,120 K
Explorer.EXE	Administrator	00	50,568 K
KAVStart.exe	Administrator	00	1,356 K
KISSvc.EXE	SYSTEM	00	3,240 K
KMAILMON.EXE	SYSTEM	00	664 K
kpfw32.exe	Administrator	00	1,180 K
KPfwSvc.EXE	SYSTEM	00	4,916 K
KWatch.EXE	SYSTEM	00	39,168 K
lsass.exe	SYSTEM	00	1,608 K
MDM.EXE	SYSTEM	00	3,664 K
NVSVC32.EXE	SYSTEM	00	4,744 K
POWERPNT.EXE	Administrator	00	4,040 K
QQ.exe	Administrator	00	39,472 K
QQ.exe	Administrator	00	23,200 K

显示所有用户的进程(S)      **结束进程(E)**

进程数: 38 | CPU 使用: 1% | 提交更改: 468M / 3421M

使用“内部标识符”控制

# 进程的特征

- 动态性
  - 进程实质是进程实体的一次执行过程  
体现在“由创建而生，由调度而执行，由撤销而亡”
- 并发性
  - 多个进程实体同存于内存中，并发执行
  - 程序(没建立PCB)是无法并发执行的。

- **独立性**
  - 进程实体是一个独立运行、独立分配资源、独立接受调度的基本单位。
  - 凡未建立PCB的程序都不能作为一个独立单位参与运行。
- **异步性**
  - 进程按各自独立的、不可预知的速度执行(即按异步方式运行)。

## • 进程是一个动态的概念

- ① 程序的一次执行。
- ② 一个程序及其数据在处理机上顺序执行时所发生的活动。
- ③ 程序在一个数据集合上运行的过程，是系统进行资源分配和调度的一个独立单位。

## ● 进程的定义

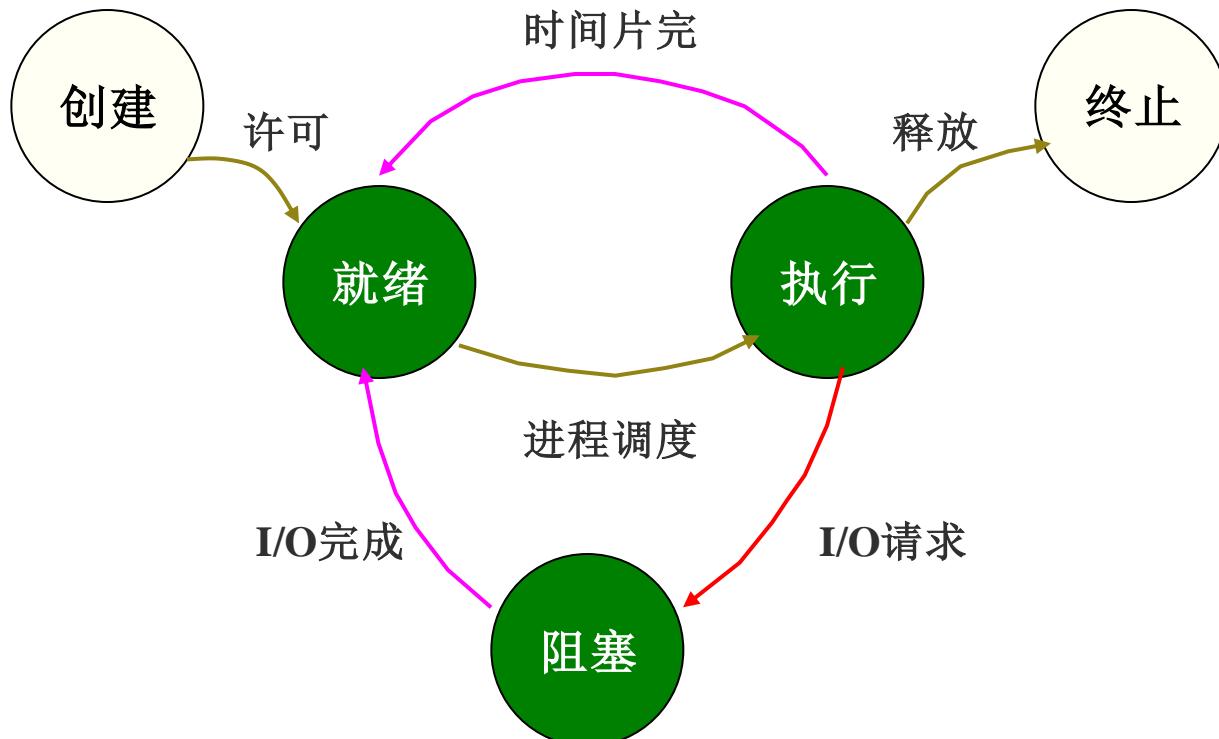
进程是进程实体的运行过程，是系统进行  
资源分配和调度的一个独立单位。

## ● 通常，也把“进程实体”简称为“进 程”

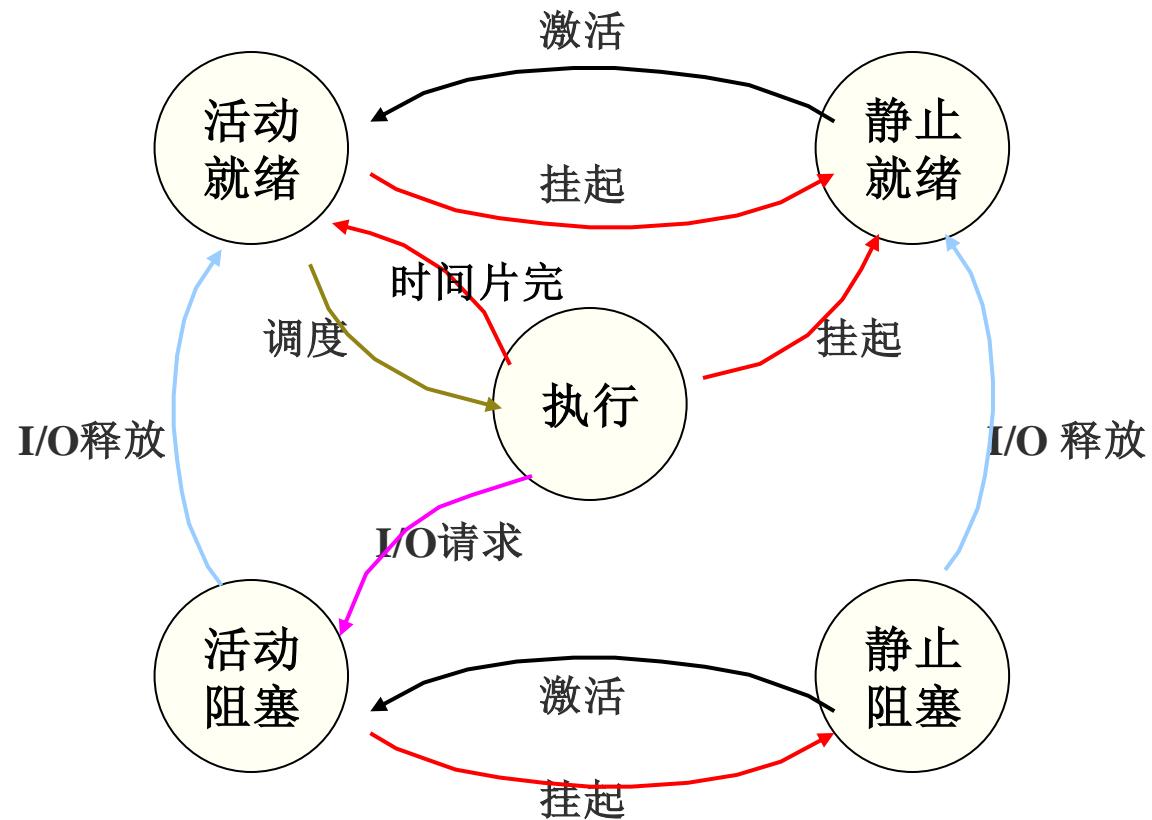
## ● 小结：对“进程”这一概念如何理解

- ① 动态的
- ② 组成
  - 给程序附加上PCB，形成了进程实体
- ③ PCB的作用
  - 保存执行过程中的一些信息，再次执行时恢复这些信息，以保证执行的正确性。
  - 也可用于OS控制和描述进程的执行。

# 进程的基本状态



# 进程的挂起状态



# 进程控制块的组织方式

- **PCB数目**

一个系统中的PCB数目可为数十个、数百个甚至数千个

- **线性方式**

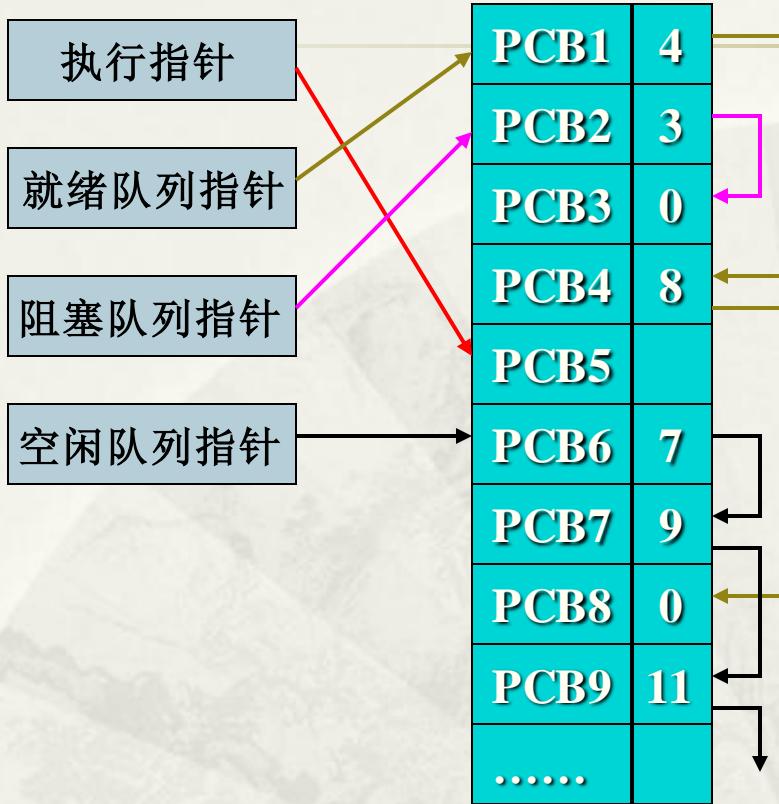
- 所有PCB都组织在一张线性表里
- 简单、开销小，但检索时浪费时间

- **链接方式**

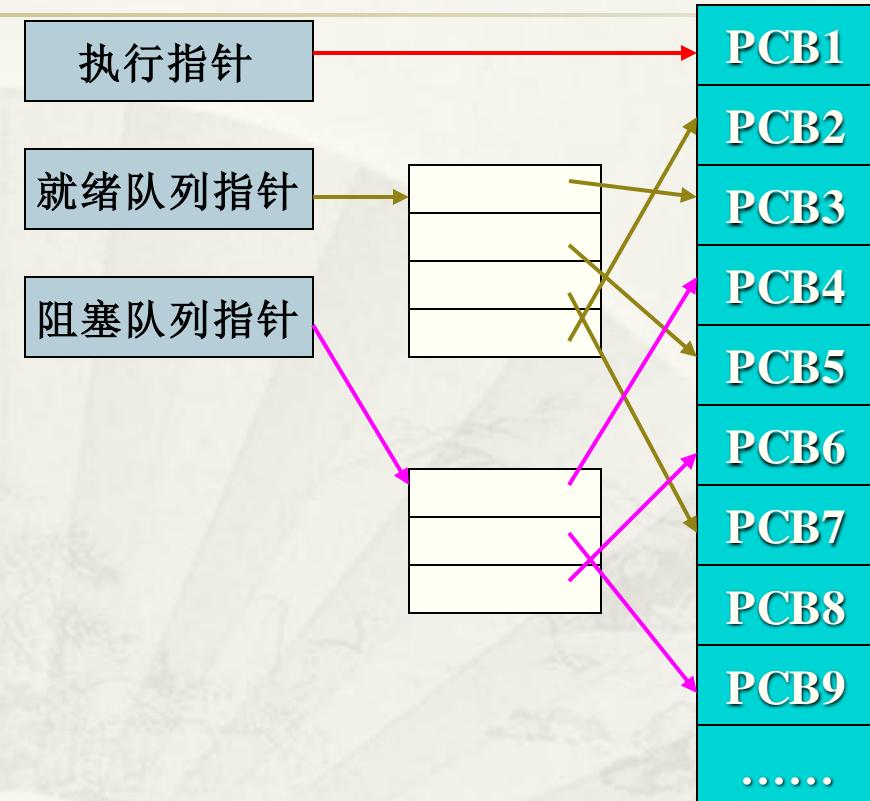
- 把具有同一状态的PCB，链接成一个队列
- 就绪队列、若干个阻塞队列、空队列

- **索引方式**

- 系统根据所有进程的状态建立相应的索引表



PCB链接队列示意图



按索引方式组织PCB

## 第三节 进程控制

- 操作系统内核
- 进程创建
- 进程终止
- 进程阻塞和唤醒
- 进程挂起与激活

由OS调用  
原语完成



# 操作系统内核

- 操作系统内核
  - 与硬件有关的模块
  - 各种常用设备的驱动程序
  - 运行频率较高的模块（时钟管理、进程调度等）
  - 常驻内存
- 优点：
  - ① 便于保护这些软件，防止遭其他程序破坏
  - ② 提高OS的运行效率

- 为防止OS遭破坏，通常将CPU的执行状态分为两种：
  - 系统态（管态、内核态）：能执行一切指令，访问所有寄存器和存储区
  - 用户态（目态）：具有较低权限，仅能执行规定的指令，访问指定的寄存器和存储区

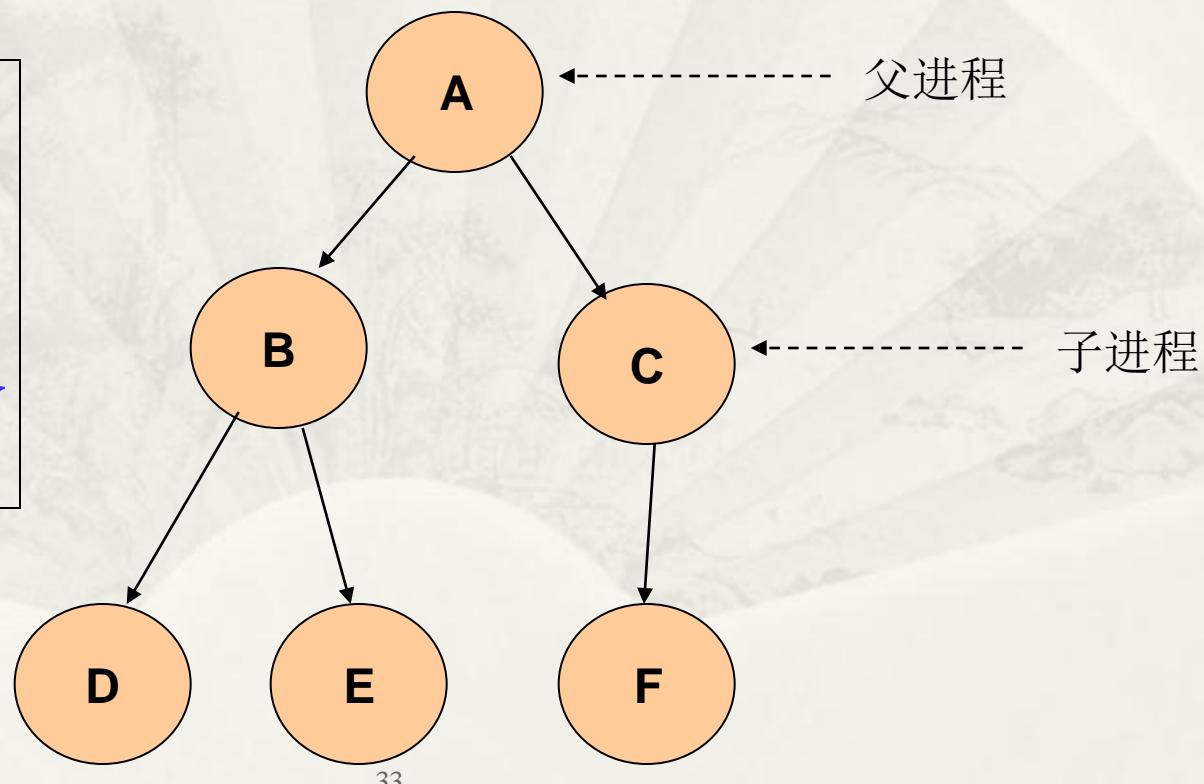
## • 原语

- 由若干条指令组成，用于完成一定功能的一个过程。
- 与一般过程/函数的区别：
  - “原子操作”：一个操作中的所有动作要么全执行，要么全不执行（它是一个不可分割的基本单位）
  - 执行过程中不允许被中断
  - 在系统态下执行，常驻内存

## • 进程图——描述一个进程家族关系的**有向树**

- 子进程可以**继承**父进程的**所有资源**(打开的文件、分配的缓冲区等)
- 撤销子进程时，把它从父进程那里获得的资源还给父进程
- 撤销父进程时，要同时撤销它所有的子进程

在PCB中设置  
家族关系表项：  
记录父进程，及  
所有的子进程

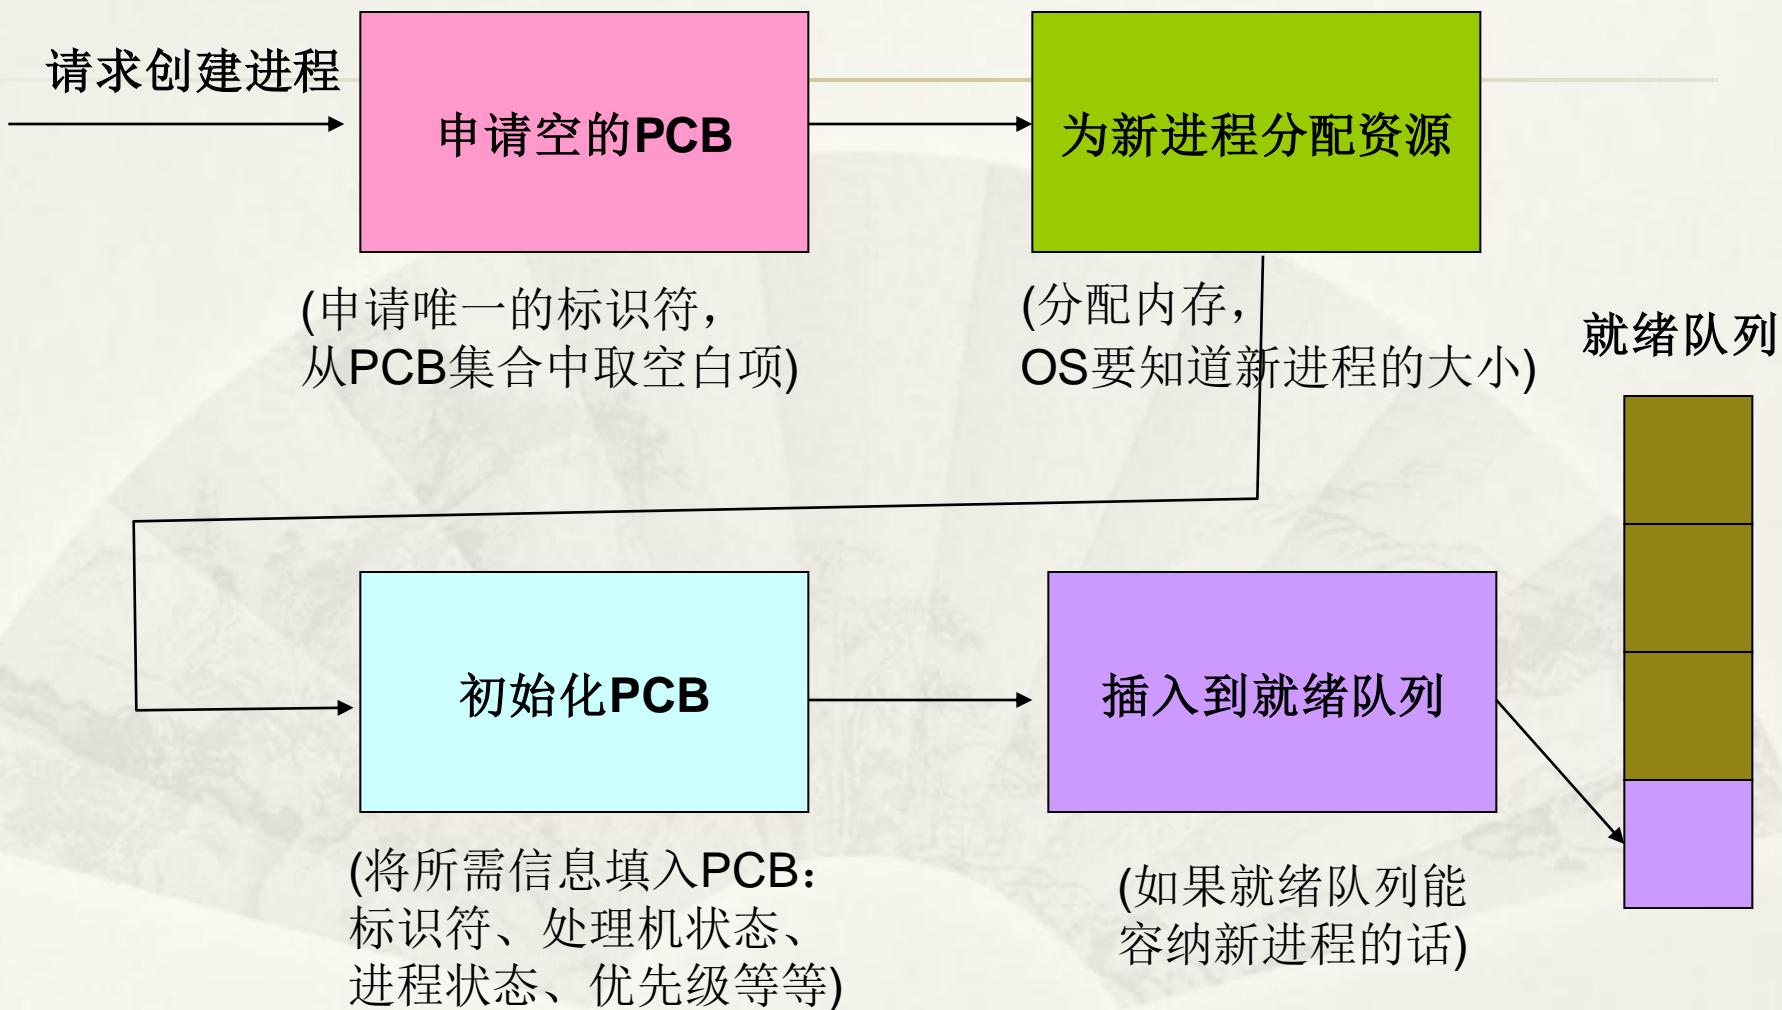


# 进程创建

## 引起创建进程的事件

- 用户登录
  - 用户从终端登录，为其建立进程(分时系统)
- 作业调度
  - 把作业装入内存 (批处理系统)
- 提供服务
  - 为某个请求创建专门的进程。例如用户打印时，创建打印进程
- 应用请求
  - 建子进程，以并发完成工作，加速任务（由应用程序创建）

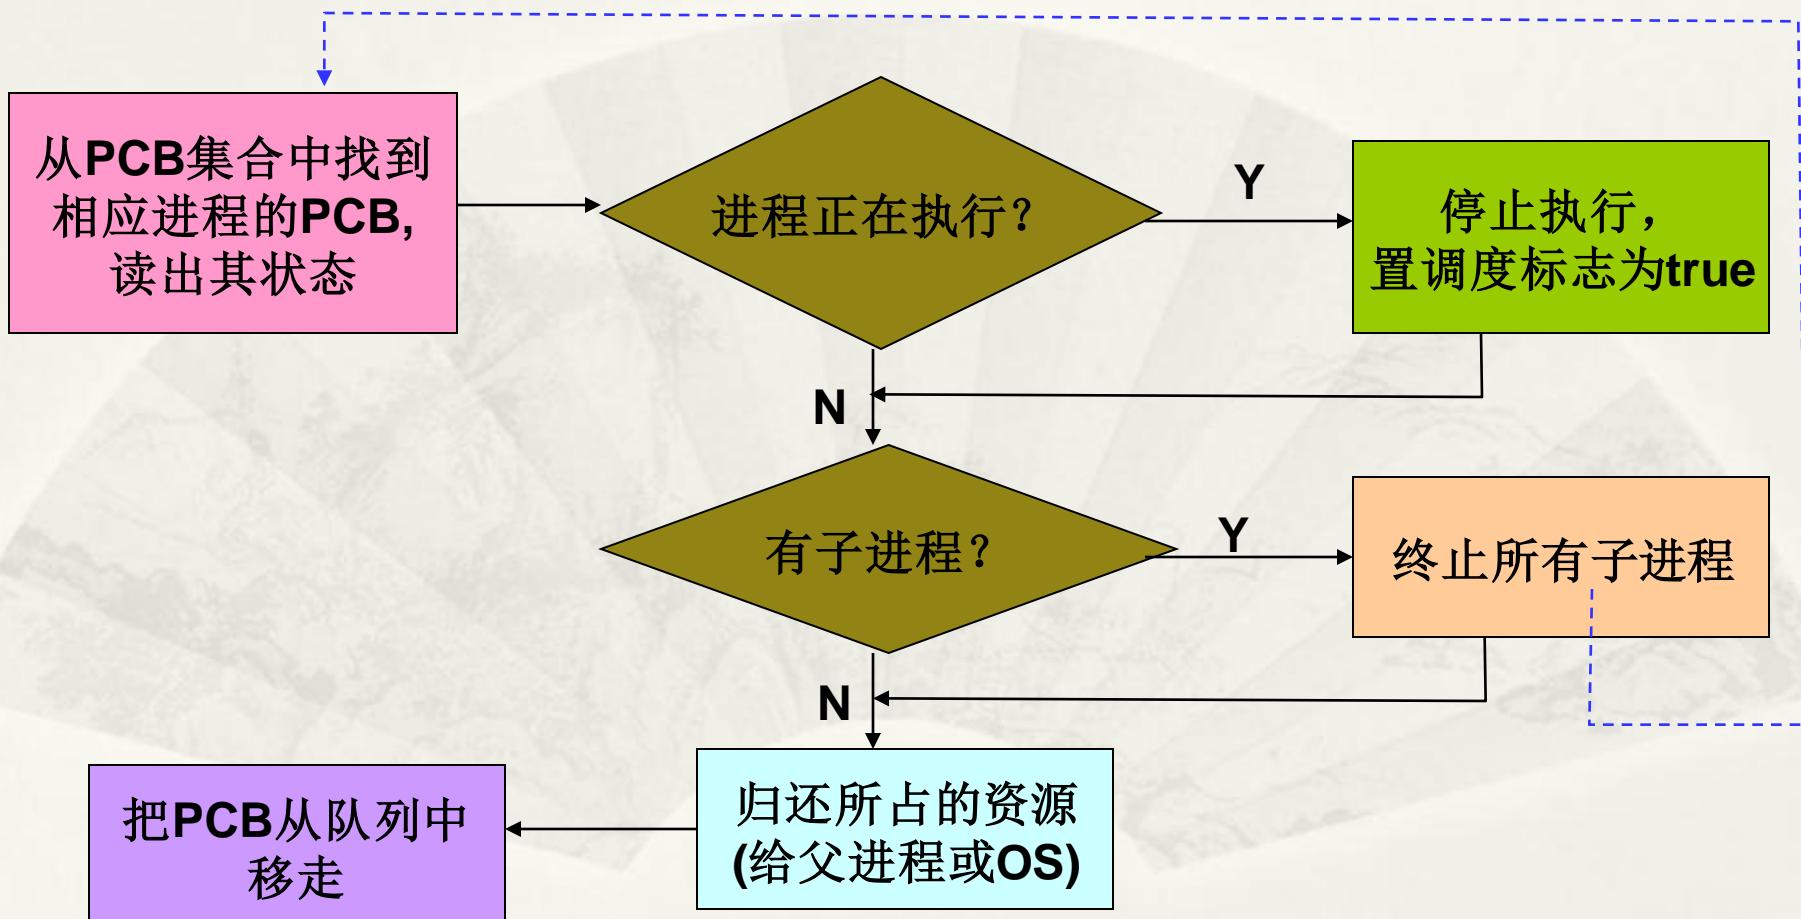
## ● 进程的创建流程



# 进程终止

- 引起进程终止的事件
  - 正常结束：执行到最后的结束指令、中断
  - 异常结束：出现错误或因故障而被迫终止
  - 外界干扰：进程应外界的请求而终止运行
- 进程终止的过程
  - 一个进程可以向其父进程申请终止自己；
  - 也可以因父进程的被终止而被同时终止。

## • 进程终止的流程



# 进程阻塞与唤醒

- 引起阻塞的事件
  - 请求系统服务失败
  - 等待某操作完成
  - 数据尚未到达
  - 等待新任务（针对系统进程）
  - 进程调用block原语阻塞自己

- 引起唤醒的事件
  - 与引起阻塞的事件相对应
- 进程调用wakeup原语唤醒另一个进程
- block原语与wakeup原语要匹配使用，以免造成“永久阻塞”

# 进程挂起与激活

- **进程挂起**

- 检查被挂进程的状态，改为相应的挂起状态
- 把进程的PCB复制到指定的区域
- 最后，转向调度程序重新调度

- **进程激活**

- 先将进程从外存调入内存
- 检查该进程的现行状态，改为相应的活动状态
- 根据优先级确定是否需要重新调度(抢占调度？)

# 小结

---

- 阻塞、唤醒一般由OS实现
  - 阻塞：进程自己的行为，进程自己阻塞自己
  - 唤醒：进程不能唤醒自己，由其他进程唤醒
- 挂起、激活可由用户干预

# 第四节 进程同步

## \* 进程同步的主要任务

- \* 协调多个相关进程的执行次序，使并发执行的进程之间能按一定的规则或时序共享资源和相互合作，从而使程序的执行具有可再现性。

# 1、基本概念

- \* 两种形式的制约关系
  - \* 直接相互制约：源于进程间的合作
  - \* 间接相互制约：源于进程对资源的共享

## \* 临界资源

- \* 具有“别人用时，你不能用”的特点
- \* 访问时，必须采用“互斥”方式

## \* 进程同步著名例子：生产者—消费者问题



要求：

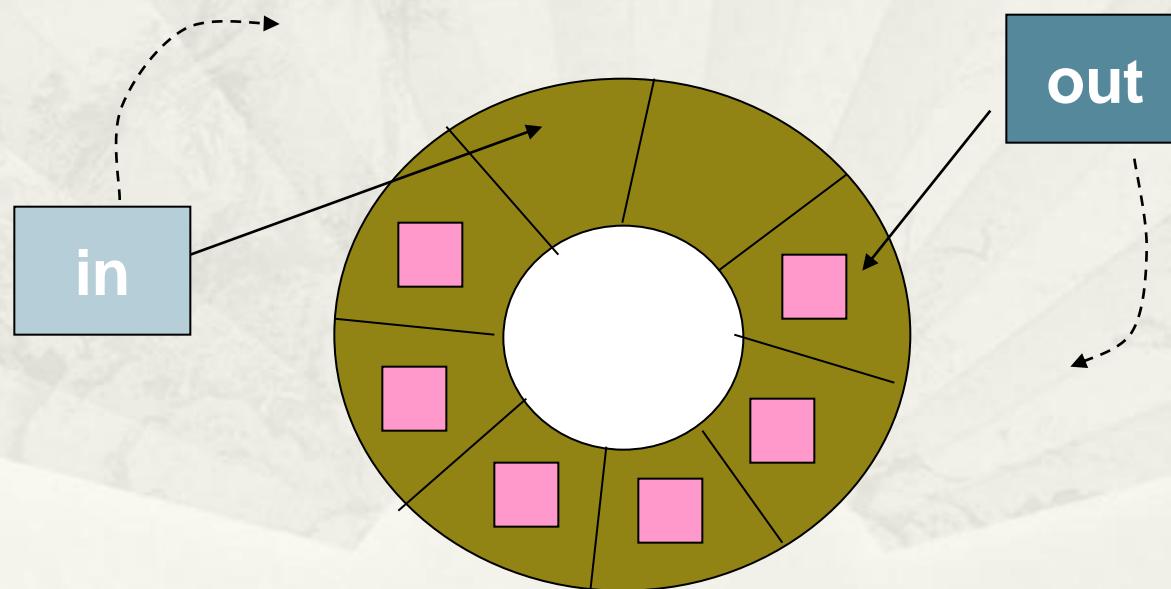
不允许生产者A向已经**满**的缓冲区**放产品**  
不允许消费者B从**空**的缓冲区**拿产品**

## \* 模拟方法：

---

- \* 缓冲区：数组  $[0, 1, \dots, n-1]$ ，循环队列
- \* 下一个产品应该放在什么位置：  $in=0, \dots, n-1$
- \* 下一个产品应该从什么位置拿：  $out=0, \dots, n-1$
- \* 缓冲区里还有多少产品：  $counter=0, \dots, n$

- \* 放一个新产品:  $in = (in + 1) \% n;$
- \* 拿走一个产品:  $out = (out + 1) \% n;$
- \* 什么时候缓冲区满了:  $counter = n$
- \* 什么时候缓冲区空了:  $counter = 0$



```
void producer()
{
    while(1)
    {
        produce an item in nextp;
        ...
        while(counter == n);
        buffer[in] = nextp;
        in = (in + 1) % n;
        counter++;
    }
}
```

```
void consumer()
{
    while(1)
    {
        while(counter == 0);
        nextc = buffer[out];
        out = (out + 1) % n;
        counter--;
        consumer the item in nextc;
        ...
    }
}
```

- \* 上面的过程在并发执行时会出错

- \* 原因：两者共享变量counter

- \* 机器语言描述：

```
mov ax, [counter]    mov bx, [counter]
```

```
inc ax            dec bx
```

```
mov [counter], ax    mov [counter], bx
```

- \* counter = 5

生产者、消费者顺序执行一次，  
结果是5

- \* 交替执行时的情况：

```
mov ax, [counter]    (ax = 5)
```

```
inc ax            (ax = 6)
```

```
mov bx, [counter]    (bx = 5)
```

```
dec bx            (bx = 4)
```

```
mov [counter], ax    (counter = 6)
```

```
mov [counter], bx    (counter = 4)
```

结果是4

- \* 刚才的例子说明什么问题?
  - \* 程序执行失去了再现性：结果可能是4或5或6
- \* 解决思路
  - \* 把counter当作临界资源处理
  - \* 令两个程序互斥访问它

- \* 临界区
  - \* 每个进程中访问临界资源的代码段
- \* 如何实现互斥地访问临界资源：
  - \* 保证各进程互斥地进入（执行）自己的临界区，便可实现对临界资源的互斥访问。

## \* 解决方法

- \* 各进程在进入自己的临界区之前，首先检查临界资源是否正在被别的进程使用/访问。

## \* 两个步骤

- ① 没被使用，则设置“使用”标志，然后使用
- ② 使用完了，设置“未用”标志，让别人可以使用

```
repeat
    entry section //进入区
    critical section; //临界区
    exit section //退出区
    remainder section; //剩余区
until false;
```

- \* 设共享变量S=1， 标志counter是否正在被使用。

生产者：

```
while(S==0); // no-op;  
S = 0;
```

```
...  
counter ++;  
...
```

```
...  
S = 1;  
...
```

消费者：

```
while(S==0); // no-op;  
S = 0;
```

```
counter --;  
...
```

```
...  
S = 1;  
...
```

并发执行的时候会出新问题！

- \* 由上可见，在程序中设置一个共享变量，用来标志另一个变量或资源是否被使用是行不通的。
- \* 所以，OS需要提供一个专门的机制，来解决这个问题。

## \* 同步机制应遵循的规则

① 空闲让进

② 忙则等待

③ 有限等待

\* 避免“死等”

④ 让权等待

\* 不能进入临界区时，立即释放处理机，避免“忙等”。

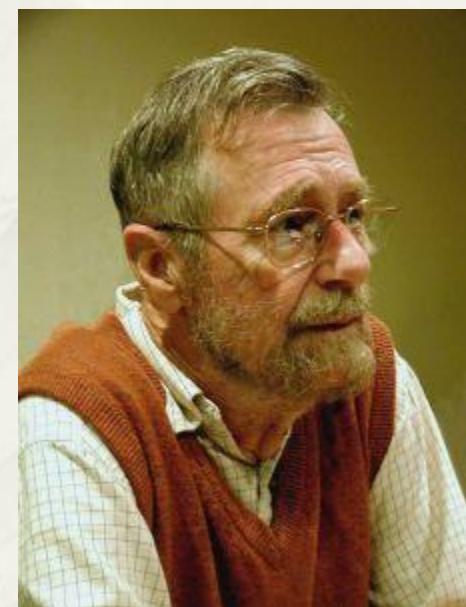
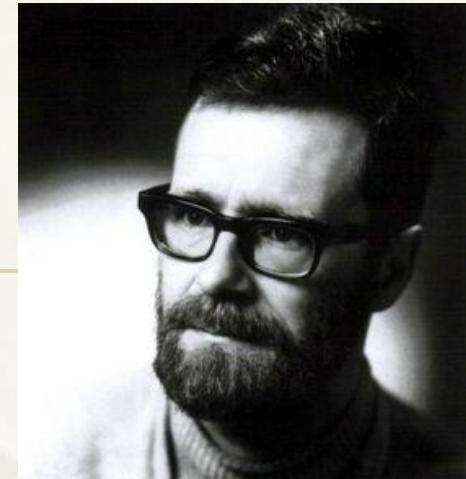
## 2、信号量机制

- \* 卓有成效的进程同步工具
- \* 提出
  - \* 1965. 荷兰 Dijkstra

# Dijkstra

## \* 经典语录

- ① 编程的艺术就是处理复杂性的艺术。
- ② 简单是可靠的先决条件。
- ③ 1972年图灵奖演讲：优秀的程序员很清楚自己的能力是有限的，所以他对待编程任务的态度是完全谦卑的，特别是，他们会象逃避瘟疫那样逃避“聪明的技巧”。
- ④ 计算机科学是应用数学最难的一个分支，所以如果你是一个蹩脚的数学家，最好留在原地，继续当你的数学家。
- ⑤ 实际上如果一个程序员先学了BASIC，那就很难教会他好的编程技术了：作为一个可能的程序员，他们的神经已经错乱了，而且无法康复。



(1930—2002)

- \* **信号量的发展**
  - \* 整型信号量 → 记录型信号量 → AND型信号量 → 信号量集
- \* **基本思想**
  - \* 使用**信号量**标记临界资源是否被使用
- \* **注意**
  - \* **检查和释放**信号量的任务由OS完成
  - \* 应用程序中可调用相应的**原语**（`wait`、`signal`），以完成对信号量的检查和释放

# 1、整型信号量

## \* 基本思想

- \* 改变**整型变量S**的值，以标记临界资源的使用情况
- \* 信号量的值只能用wait(S)和signal(S)来访问
- \* S的初始值为1或更大。

```
wait(S){  
    while(S<=0); // do no-op  
    S --;  
}
```

```
signal(S) { S++;}
```

wait(S)、signal(S)是**原子操作**，执行时不可中断。  
(又被称作P、V操作)

- \* 整型信号量机制的缺点
  - \* 只要信号量 $S \leq 0$ , 就会不停地测试。
  - \* 因此, 未遵循“让权等待”准则——“忙等”。
- \* 故而, 引入“记录型信号量机制”, 避免“忙等”现象。

## 2、记录型信号量

### \* 组成部分

- \* 整型变量 value：表示资源数目
- \* 链表 list：等待访问该资源的进程形成的阻塞队列

### \* 数据结构定义

```
typedef struct{  
    int value; //资源数目  
    struct process_control_block *list;//阻塞队列  
} semaphore;
```

- **wait(semaphore \*S):**

```
S->value --;
```

// 如果资源分配完毕，

// 自我阻塞,进入队列

// S.L进行等待

```
if (S->value<0)
```

```
block(S->list);
```

- **signal(semaphore \*S):**

```
S->value ++;
```

//如果S.value<=0,

//表示仍有等待的进程，

//则唤醒一个

```
if (S->value<=0)
```

```
wakeup(S->list);
```

注意： S.value < 0时， |S.value| 表示被阻塞进程的数目

- \* **一个现实的问题**

---

- \* 如果进程需要获得多种资源后才能继续执行，如何实现同步？

- \* **一种解决方法**

- \* 使用前面讲的信号量机制能否解决？

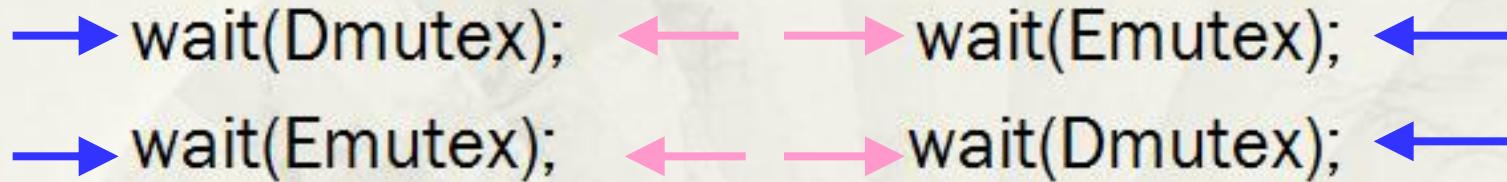
- \* **答案**

- \* 不行！！！(why?)

例子：进程A、B访问共享变量D和E，为D和E各设一个互斥信号量Dmutex=1和Emutex=1。

A阻塞

B阻塞



Dmutex = -1

Emutex = -1

## 执行顺序：

A: wait(Dmutex); → Dmutex = 0

B: wait(Emutex); → Emutex = 0

A: wait(Emutex); → ∵ Emutex = -1 ∴ A阻塞

} 僵持，死锁

B: wait(Dmutex); → ∵ Dmutex = -1 ∴ B阻塞

阻塞以后，A和B代码后面的Signal无法执行，也就无法改变Dmutex和Emutex的值，从而死锁

● 为解决以上问题，引入“AND型信号量”

### 3、AND型信号量

- \* 基本思想
  - \* 一次性分配进程执行过程中所需要的全部资源，待使用完后再一并释放。
  - \* 即使只有一个资源无法分配，其他的资源也都不分配。
  - \* 也即，要么全分配，要么一个也不分配

## ● Swait(S1,...,Sn)

```
{  
    if (S1>=1 && ... && Sn>=1)  
    {  
        for(i= 1; i<=n; i++)  
            Si --;  
    }  
    else{ 将进程阻塞， 放入第一个发现si<1的等待队列中；  
          将进程指针指向Swait开头; }  
}
```

## ● Ssignal(S1,...,Sn)

```
{  
    for(i=1;i<=n;i++)  
    { Si ++;  
        将si等待队列中的进程  
        转入就绪队列;}  
}
```

- \* **一个现实的问题**

- \* 如何一次申请N个同类资源？

- \* **一种解决方法**

- \* 使用前面讲过的信号量机制？

- \* **回答**

- \* 申请N个，要调用N次wait()，效率低

- \* 另外，也无法满足“当资源数低于某个下限值时，便不分配”的需求。

- \* 所以，引入**“信号量集”机制**

## 4. 信号量集

- \* 对“AND信号量”机制进行改进，形成一般化的“信号量集”机制。
- \* 基本思路
  - \* 每次分配之前，必须测试该资源的数量，看其是否大于其下限值。
  - \* 因此，除信号量S外，还设置资源的需求量d，和资源的下限值t

$S_{wait}(S_1, t_1, d_1, \dots, S_n, t_n, d_n)$

$S_{signal}(S_1, d_1, \dots, S_n, d_n)$

- $S_i >= t_i$  才能分配资源
- 分配时:  $S_i = S_i - d_i$

## \* “信号量集”的几种特殊使用

① Swait(S,d,d)

- 只有一个信号量，每次分d份资源，当资源数少于d时，不给分配。

② Swait(S,1,1)

- 蜕化为一般记录型信号量( $S>1$ )或互斥信号量( $S=1$ )

③ Swait(S,1,0)

- 特殊且有用的信号量——功能类似于“开关”。
- $S \geq 1$ 时，允许多个进程执行某特定的代码。
- 置 $S=0$ 后，阻止任何程序执行该段代码。

## 4、信号量的应用

- \* **信号量机制的用途一般有三种**
  - ① 用于“限制”访问:
    - \* 限制进程互斥地访问共享资源
    - \* 限制进程访问有限数量的共享资源
  - ② 用于“协调”执行:
    - \* 协调进程间的执行次序  
(实现进程间的协调, 即实现前趋关系)

# 1、利用信号量实现进程互斥

- \* 如何让多个进程互斥访问一个临界资源?
- \* **方法**
  - ① 设一个信号量mutex，令其初始值为1(互斥信号量)，用它控制进程的访问。
  - ② 将各进程访问临界资源的代码放入wait(mutex)和signal(mutex)之间。

```
semaphore mutex= 1; //定义信号量
```

```
while(1){
```

```
    wait(mutex);
```

临界区：使用/访问临界  
资源的代码

```
    signal(mutex);
```

...

```
}
```

- 注意：**利用信号量实现进程互斥时，`wait`、`signal` 一般要成对出现
- 缺少**wait**：**导致系统混乱。
- 缺少**signal**：**使阻塞进程无法被唤醒。

```
while(1){
```

```
    wait(mutex);
```

临界区：使用/访问临界  
资源的代码

```
    signal(mutex);
```

...

```
}
```

## 2、利用信号量实现进程访问有限数量的共享资源

- \* 如果共享资源的数量有限（设 $>1$ ），如何控制多个进程对它们的访问？
- \* 方法
  - ① 设一个信号量mutex，令其初始值等于共享资源的数量，用它控制进程的访问。
  - ② 将各进程访问共享资源的代码放入`wait(mutex)`和`signal(mutex)`之间。

**semaphore mutex= 资源数量; //定义信号量**

**while(1){**

**wait(mutex);**

**使用/访问共享  
    资源(共享变量)的代码**

**signal(mutex);**

**...**

**}**

**while(1){**

**wait(mutex);**

**使用/访问共享  
    资源(共享变量)的代码**

**signal(mutex);**

**...**

**}**

- 注意事项与使用互斥信号量时相同

### 3、利用信号量协调进程执行(实现前趋关系)

- 例1：设并发执行的两个进程P1、P2

P1: S1

P2: S2

要求： S1在S2之前执行

前驱图:



方法: 设置信号量  $\text{mutex}=0$  (why?)

P1: **S1;**

**signal(mutex);**

P2: **wait(mutex);**

**S2;**

## ■ 例2：利用信号量实现语句间的前趋关系

semaphore a=b=c=d=e=f=g=0;

P1(){S1; signal(a); signal(b);}

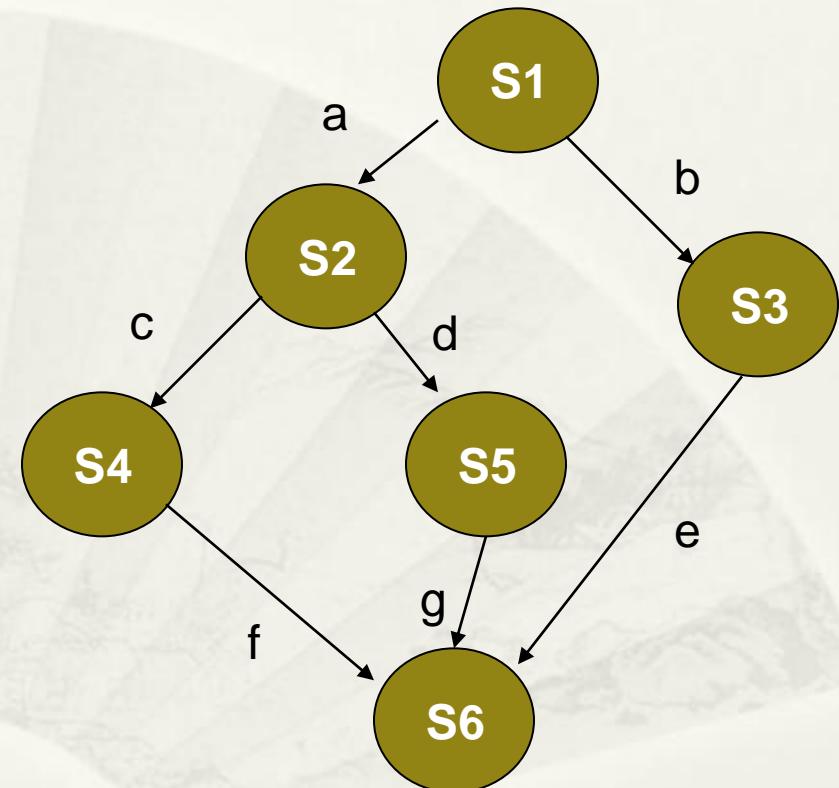
P2(){wait(a); S2; signal(c); signal(d);}

P3(){wait(b); S3; signal(e);}

P4(){wait(c); S4; signal(f);}

P5(){wait(d); S5; signal(g);}

P6(){wait(e); wait(f); wait(g); S6;}



# 信号量小结

- \* **信号量应用分类：**

“限制”：信号量的wait、signal在**同一个进程中**

“协调”：信号量的wait、signal在**不同的进程中**

# 练习题

\* 公交车上，司机和售票员的活动分别为：

司机：

启动汽车

正常行驶

到站停车

开车门

售票员：

上下乘客

关车门

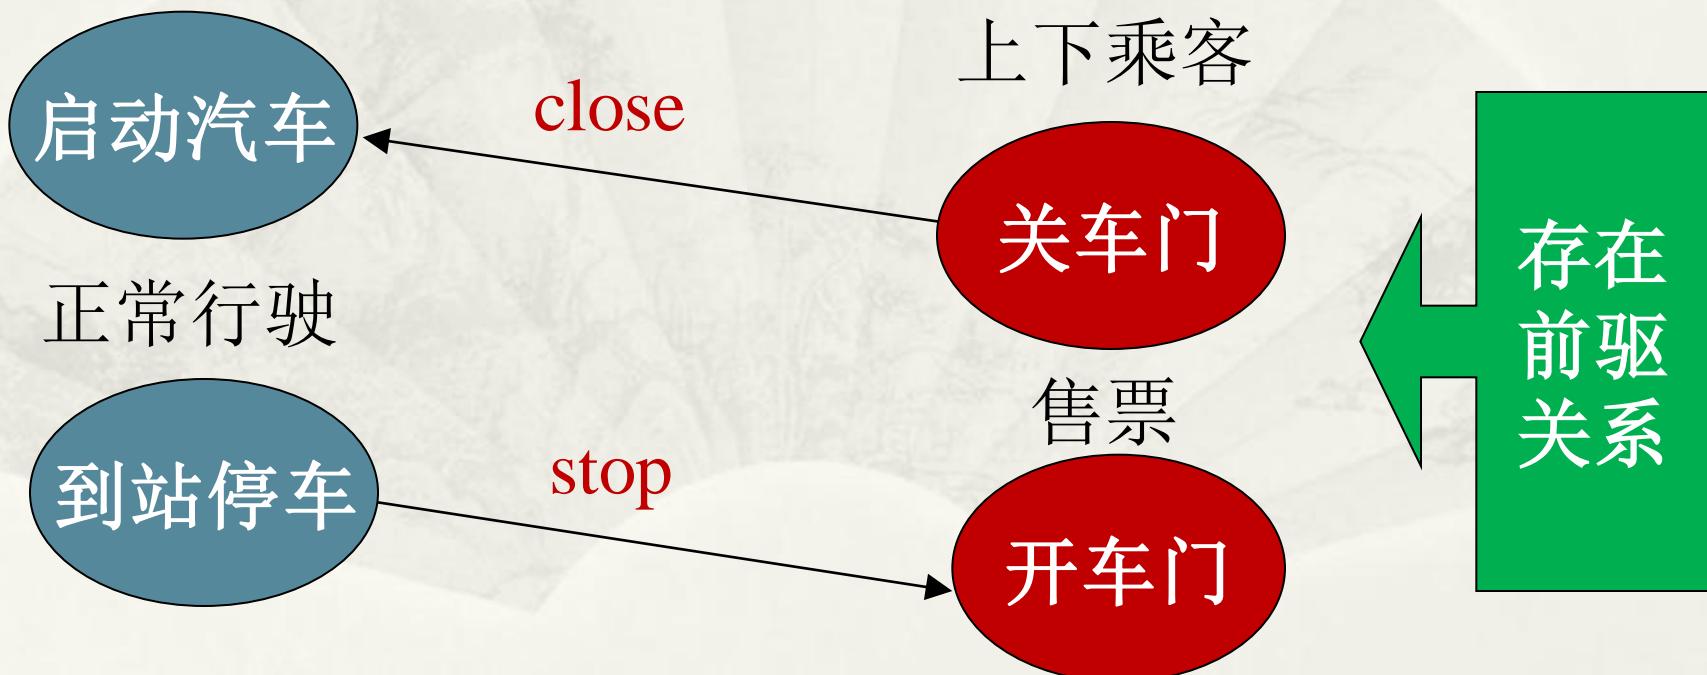
售票

问：二者活动之间有什么同步关系，请用信号量机制实现二者的活动。

## \* 解答

### \* 二者的活动关系：

- ① 司机启动汽车前，售票员必须已关闭车门
- ② 售票员开车门前，司机必须已到站停车



semaphore stop=0, close=0;

---

司机:

```
while(1){  
    wait(close);  
    启动汽车;  
    正常行驶;  
    到站停车;  
    signal(stop);  
}
```

售票员:

```
while(1){  
    上下乘客;  
    关车门;  
    signal(close);  
    售票;  
    wait(stop);  
    开车门;  
}
```

# 第四节 经典进程同步问题

- \* **经典进程同步问题：**

1. 生产者-消费者问题
2. 哲学家进餐问题
3. 读者-写者问题

# 1. 生产者-消费者问题

## 思路1

- 利用“记录型信号量”解决

## 方法

- 设三个信号量

- ① 互斥信号量 **mutex**

- 用于各进程对缓冲区的互斥访问

- ② 信号量**empty**、**full**

- 分别表示缓冲区中**空缓冲单元**和**满缓冲单元**的数量

```
semaphore mutex=1, empty=n, full=0; // 定义信号量
item buffer[n]; // 定义缓冲区
int in=0, out=0; // 定义下标指示变量
void producer() //生产者如何执行(如何往缓冲区放东西)
{
    do{
        产生一个商品放入nextp中;
        wait(empty); //等待缓冲区有地方
        wait(mutex); //等待可以使用缓冲区
        buffer[in] = nextp;
        in = (in + 1) % n;
        signal(mutex); //告诉其他进程:缓冲区可以使用了
        signal(full); //告诉其他进程:缓冲区多了一个商品
    }while(1);
}
```

```
void consumer() //消费者如何执行(如何从缓冲区取东西)
{
    do{
        wait(full); //等待缓冲区有商品
        wait(mutex); //等待可以使用缓冲区
        nextc = buffer[out];
        out = (out + 1) % n;
        signal(mutex); //告诉其他进程:缓冲区可以使用了
        signal(empty); //告诉其他进程:缓冲区空出一个地方
        消费商品 nextc;
    }while(1);
}
```

\* 注意

- \* wait(mutex)和signal(mutex)必须成对出现
- \* empty、full的wait、signal也要成对出现
- \* 注意多个wait的顺序不能颠倒。

- \* 颠倒wait的顺序以后可能会死锁，比如：

- 生产者p: 消费者c:

---

wait(empty);	wait(mutex);
--------------	--------------

wait(mutex);	wait(full);
--------------	-------------

**信号量初始值： mutex:=1, empty:=n, full:=0**

- 执行顺序：

c的wait(mutex) → mutex=0

c的wait(full) → ∵ full=0 ∴ c阻塞

p的wait(empty) → empty=n-1

p的wait(mutex) → ∵ mutex=0 ∴ p阻塞

僵持状态，  
死锁

- \* 思路2
  - \* 利用AND信号量解决
  - \* 可避免因为wait顺序书写错误，引发的死锁问题
- \* 方法
  - \* 生产者:

...

Swait(empty.mutex);

buffer[in] = nextp;

in := (in + 1) % n;

Ssignal(mutex,full);

\* 消费者:

Swait(full.mutex);

nextc = buffer[out];

out = (out + 1) % n;

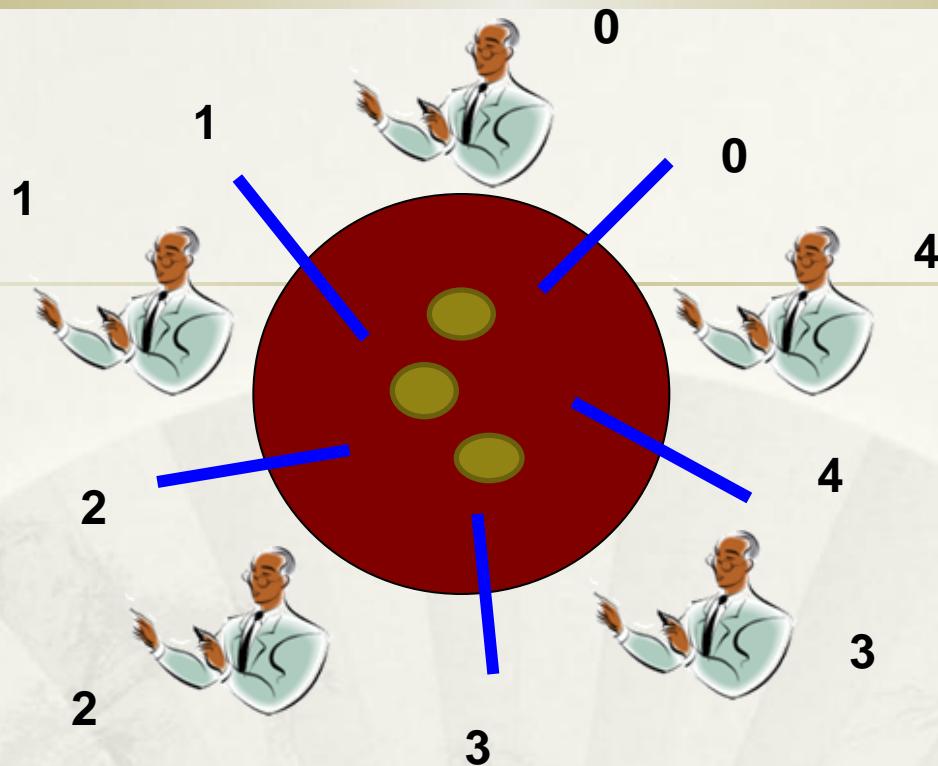
Ssignal(mutex,empty);

...

## 2、舌尖上的哲学家

- 哲学家进餐问题

- 提出者：Dijkstra
- 描述
  - \* 5个哲学家共用一张圆形餐桌，
  - \* 桌子上放着5支筷子、5只碗。
  - \* 他们吃饭和思考交替进行。
  - \* 吃饭时只能拿自己左右两侧的筷子，
  - \* 不吃时放下筷子进行思考，周而复始。



- 筷子是共用的。身边任何一个人吃饭,自己就没法吃(缺少筷子)
- 所以, 每根筷子都是临界资源 (每次只允许一位哲学家使用)
- 可以为每根筷子设置一个信号量 (实现对筷子的互斥使用)

- \* 思路1

- \* 利用记录型信号量

- \* 方法

```
semaphore chopstick[5]={1,1,1,1,1};  
void philosopher(int i) //第i个哲学家的活动  
{ do{  
    wait(chopstick[i]); //拿左筷子  
    wait(chopstick[(i+1) % 5]); //拿右筷子  
    吃饭;  
    signal(chopstick[i]); //放左筷子  
    signal(chopstick[(i+1) % 5]); //放右筷子  
    思考;  
}while(1);  
}
```

## • 缺点

- \* 如果每个人开始都**先拿自己左边的筷子**
- \* 可能导致人手一根筷子，而拿不到第二根筷子
- \* 从而全部阻塞，引起死锁。

## • 解决办法

- ① 至多只允许四个人“同时”拿左边的筷子，最终保证至少一个人能吃上饭。
- ② 仅当左右筷子均可用时，才允许他拿筷子进餐。(AND信号量)
- ③ 规定**奇数号**哲学家先拿起他**左边**的筷子，再拿右边的筷子；而**偶数号**哲学家先拿起他**右边**的筷子，再拿左边的筷子。

- \* 思路2

- \* 利用AND型信号量

- \* 方法

```
semaphore chopstick[5]={1,1,1,1,1};
```

```
void philosopher(int i)
```

```
{ do{
```

```
    Swait(chopstick[i], chopstick[(i+1)%5]);
```

```
    吃饭;
```

```
    Ssignal(chopstick[(i+1)%5], chopstick[i]);
```

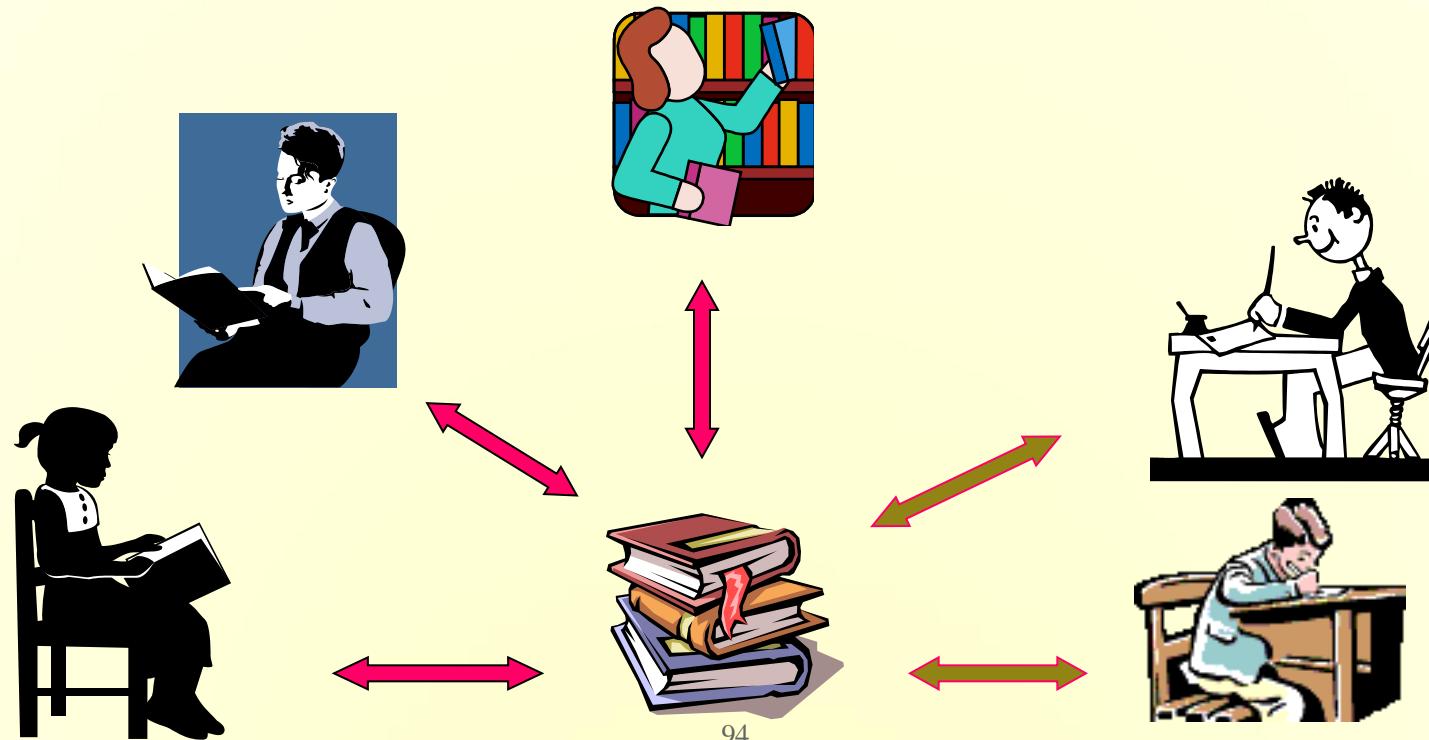
```
    思考;
```

```
 }while(1);
```

```
}
```

### 3、读者—写者问题

- 有两组并发进程：读者、写者，共享一组数据区
- 要求：
  - 允许多个读者同时执行读操作
  - 不允许读者、写者同时操作（读写互斥）
  - 不允许多个写者同时操作（只能一人写）



## \* 利用记录型信号量

- \* 用信号量wmutex控制写者与其他进程的互斥
- \* 设整型变量readcount，记录正在进行读操作的读者数目
  - ∴ readcount=0时，写者才可以写
  - ∴ 只有这时，读者才需要执行wait(wmutex)，看看是否有写者在写
- \* 因为readcount被所有读者共享，所以还要用信号量rmutex控制它们对readcount的操作。

```
semaphore rmutex=1, wmutex=1;
```

```
int readcount=0;
```

读者进程：

```
do{
```

```
    wait(rmutex);
```

```
    if (readcount==0)
```

```
        wait(wmutex);
```

```
    readcount ++;
```

```
    signal(rmutex);
```

读操作；

```
    wait(rmutex);
```

```
    readcount --;
```

```
    if (readcount == 0)
```

```
        signal(wmutex);
```

```
    signal(rmutex);
```

```
}while(1);
```

写者进程：

```
do{
```

```
    wait(wmutex);
```

写操作；

```
    signal(wmutex);
```

- readcount是临界资源，需要用信号量控制

- 如果没有读者在读，再看看是否有写者在写

- 如果没有其他读者在读的话，就通知写者说现在可以写了

- \* 新要求
  - \* 如果最多只允许RN个读者读，该怎么解决？
- \* 利用信号量集解决
  - \* 方法
    - ① 设信号量L，初始值为RN，以控制读者的数目
      - \* 每当有一个读者要读时，执行swait(L,1,1),使L减1
      - \* 当有RN个读者正在读时，L=0
      - \* 再来一个读者要读的话，便会被阻塞。
    - ② 设信号量mx，初始值为1(互斥信号量)，以控制写者

- 如果已有一个写者在写，则有 $mx=0$
  - 如果已有至少一个读者在读，则有 $L < RN$
  - 存在以上两种情况之一时，本写者阻塞并等待
  - 否则表示，没有其他写者在写，并且没有读者在读，则置 $mx=1$ 并继续下一步
- 注：若有读者在读，改 $L$ ；若有写者在写（只检查，不修改 $mx$ 的值）

## 写者进程：

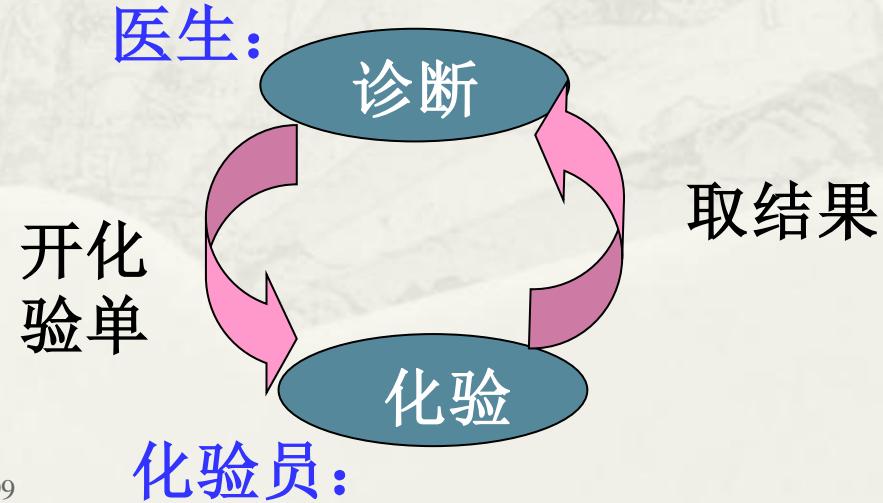
正在读操作的读者数目是否  
**Swait (mx,1,1;L,RN,0);**

如果 $L \geq 1$ ，说明还允许新读者，则将 $L$ 减1，并继续执行下一步  
否则，说明已有 $RN$ 个读者在读，则阻塞并等待

# 信号量机制 练习题

1、医生诊病的过程如下：

- 看病 → 开化验单 →  
病人取样送化验室 → 等化验完毕  
→ 交回化验结果给医生 →  
医生继续诊病
- 请用两个进程模拟医生和化验员的活动，并实现二者之间的同步



## \* 解答

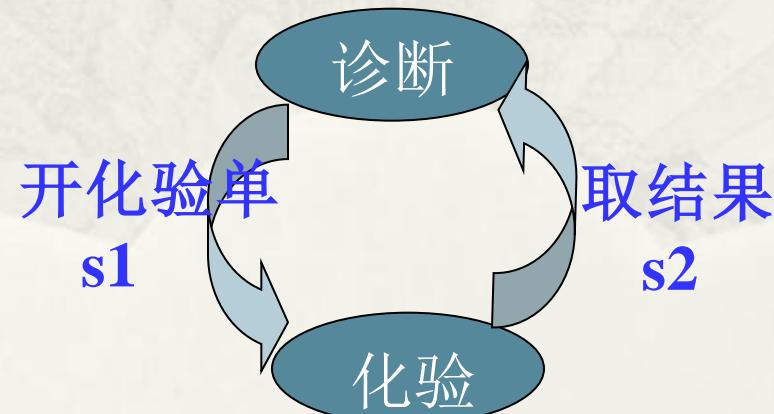
```
semaphore s1=0, s2=0;;
```

化验员:

```
do{  
    wait (s1);  
    化验;  
    signal (s2) ;  
}while(1);
```

医生:

```
do{  
    诊断;  
    signal(s1);  
    wait (s2);  
}while(1);
```



## 2、描述一个没有死锁的解决哲学家进餐问题的算法

- ① 让奇数号的哲学家先右后左的筷子，让偶数号的哲学家先左后右的筷子

```
semaphore chopstick [5]={1,1,1,1,1};
```

```
void philosopher(int i)
{
    while(1)
    { if ( i % 2==0)                      吃饭;
        { wait (chopstick[i]);
          wait (chopstick[(i+1) % 5]);
        }
        signal (chopstick[i]);
        signal(chopstick[(i+1) % 5]);
        思考;
    }
}
```

② 最多允许四位哲学家拿起筷子。

- semaphore chopstick[5]={1,1,1,1,1};

```
semaphore max = 4;
```

```
void philosopher(int i)
```

```
{ while(1)
```

```
 { wait(max);
```

```
 wait(chopstick[i]);
```

```
 wait(chopstick[(i+1) %5]);
```

```
吃饭;
```

```
signal(chopstick[i]);
```

```
signal (chopstick [(i+1) % 5]);
```

```
signal (max);
```

```
思考;
```

```
}
```

```
}
```

### 3、售票问题

- \* 某车站售票厅，任何时刻最多可容纳 20 名购票者进入。
- \* 当售票厅中少于 20 名购票者时，厅外的购票者可立即进入，否则需在外面等待。
- \* 若把一个购票者看作一个进程，请回答下列问题：
  - ① 用 wait、signal 操作管理这些并发进程时，应怎样定义信号量，写出信号量的初值以及信号量取值的含义。
  - ② 写出购票者进程的算法描述。

## 解答

① 定义信号量empty=20， 代表可以进入的购票者人数

② semaphore empty= 20;

```
void person()
```

```
{
```

```
    wait(empty);
```

进入售票厅；

购票；

退出；

```
    signal(empty);
```

```
}
```

## 4、单行车道问题

- \* a, b 两点间是一段东西向的单行车道
- \* 请设计一个自动管理系统，管理规则如下：
  - ① ab段间有车辆行驶时，同方向的车可以同时进入，但另一方向的车必须在段外等待；
  - ② ab之间无车时，到达a（或b）的车辆可以进入，但不能从a、b点同时进入；
  - ③ 某方向在ab段行驶的车辆驶出了ab段且无车辆进入时，应让另一方向等待的车辆进入。
- \* 请用信号量机制对ab段实现正确管理

a



b

## • 分析

- \* 定义两个进程 $P_{ab}$ 、 $P_{ba}$ ，分别实现对汽车从a端或b端进入时的道路控制
  - \* 每当有汽车要进入道路时，便相应调用 $P_{ab}$ 或 $P_{ba}$
- \* 定义两个变量 $countab$ 、 $countba$ ，分别记录从a端或b端进入的汽车数量
  - \* 每当有汽车进入时，都要检查或改变它们，因此它们属于临界资源，对它们的访问需要用信号量控制
  - \* 因此，再设两个互斥信号量 $mutexab$ 、 $mutexba$
- \* 定义互斥信号量 $s$ ，用于实现汽车“不能从a、b点同时进入”

```
semaphore s=1, mutexab=1, mutexba =1;  
int countab=0, countba=0;  
void P_ab()  
{  
    wait(mutexab);  
    countab++;  
    if (countab==1) wait(s);  
    signal(mutexab);  
    进入;  
    wait(mutexab);  
    countab - -;  
    if (countab==0) signal(s);  
    signal(mutexab);  
}
```

```
void P_ba()  
{  
    wait(mutexba);  
    countba++;  
    if (countba==1) wait(s);  
    signal(mutexba);  
    进入;  
    wait(mutexba);  
    countba - -;  
    if (countba==0) signal(s);  
    signal(mutexba);  
}
```

## 5、阅览室问题

- \* 有一个阅览室，读者进入时必须在一张登记表上登记
- \* 该表中每一座位列为一表目，包括座号和读者姓名。
- \* 读者离开时要消掉登记信息，阅览室中共有100个座位
- \* 请问：
  - ① 为描述读者动作，应设几个进程
  - ② 用信号量机制实现进程间的同步

分析：登记表是临界资源 —— 设信号量  $\text{mutex} = 1$   
用两个信号量分别表示座位的数量和在读读者的数量  
——  $\text{seat} = 100$ ,  $\text{reader} = 0$

# 解答：

(1) 2个进程

(2)

```
semaphore seat=100, reader=0, mutex=1;
```

```
void P1()
{
    do {
        wait(seat);
        wait(mutex);
        登记信息;
        signal(mutex);
        signal(reader);
        就座，阅读;
    } while(1);
}
```

```
void P2()
{
    do {
        wait(reader);
        wait(mutex);
        消掉信息;
        signal(mutex);
        signal(seat);
        离开阅览室;
    } while(1);
}
```

# 第六节 进程通信

- \* 进程通信的概念
- \* 进程通信的类型
- \* 消息传递通信的实现方法
- \* 消息传递系统实现中的若干问题
- \* 消息缓冲队列通信机制

# 1、进程通信的概念

- \* **进程通信**，是指进程之间的信息交换
- \* **低级通信**（互斥、同步）
  - \* 利用信号量机制实现进程间的数据传递
  - \* 缺点：效率低；对用户不透明
- \* **高级通信**（进程通信）
  - \* 进程之间利用OS提供的一组通信命令，高效地传送大量数据的信息交换方式
  - \* 优点：高效，方便，简化了通信程序的设计

## 2、进程通信的类型

### ● 高级通信机制的类型

- ① 共享存储器系统
- ② 管道通信系统
- ③ 消息传递系统
- ④ 客户机-服务器系统

①

## 共享存储器系统

- \* 基于共享数据结构的通信方式
  - \* 进程共享某些数据结构(如队列)
  - \* 程序员必须负责同步管理
  - \* 所以**低效**，只适合**传输少量数据**
- \* 基于共享存储区的通信方式
  - \* 属于高级通信方式
  - \* **划出一块共享存储区**，进程通过对存储区中数据的读写来通信

②

## 管道通信系统

- \* 首创于UNIX系统

### 管道

- \* 是一个共享文件（pipe文件），用于连结一个发送进程和一个接收进程，以实现通信
- \* 发送进程和接收进程利用管道进行通信
- \* 管道机制还提供三个方面的协调能力

#### ① 互斥

- \* 一个进程读/写管道，另一进程必须等待

#### ② 同步

- \* 发送进程写入一定数量的数据后便阻塞，接收进程取走后再唤醒
- \* 接收进程读到空管道时，也会阻塞，有数据时才被唤醒

#### ③ 确定对方都存在后，才进行通信

③

## 消息传递系统

- \* 进程间交换的数据是有格式的，称为 message（网络通信中，称为报文）
- \* OS提供了相应的通信命令

④

## 客户机-服务器系统

- \* 主流通信机制
- \* 实现方法：
  - ① 套接字
  - ② 远程过程(方法)调用

# 3、消息传递通信的实现方式

## ① 直接消息传递系统（直接通信方式）

- \* 发送进程利用OS提供的发送原语，直接把消息发  
送给目标进程
  - \* **Send (Receiver, message)**
  - \* **Receive (Sender, message)**

## ② 信箱通信（间接通信方式）

- 进程之间通过共享数据结构（信箱），以消息暂存方式实现的通信
- 操作原语
  - 信箱的创建、撤销；消息的发送、接收
- 信箱的创建和拥有者
  - OS或用户（通信）进程
- 信箱的种类
  - 私用信箱、公用信箱、共享信箱
- 利用信箱通信时，发送和接收进程之间的关系
  - 一对一、多对一、一对多、多对多

# 4、消息缓冲队列通信机制

- \* 提出者：Hanson
  - \* 通过内存中的**消息缓冲区**进行进程通信
  - \* 广泛应用于本地进程间通信
- \* **发送原语** send(receiver , a)
  - \* a: 发送区的地址
- \* **接收原语** receive(b)
  - \* b: 接收区的地址

## (1) 消息缓冲区中的数据结构:

```
struct message_buffer {  
    int sender ; //发送进程标识符  
    int size ; //消息长度  
    char *text; //消息正文  
    struct message_buffer *next; //下一消息缓冲区指针  
};
```

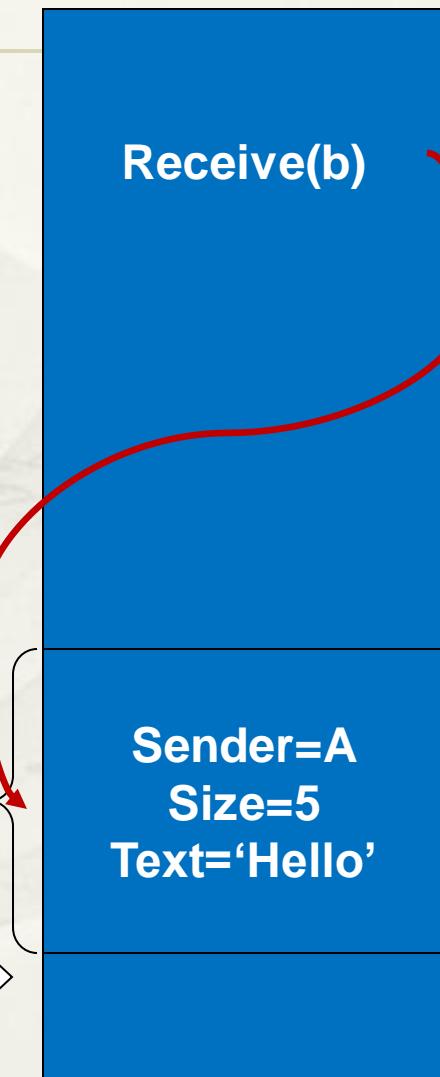
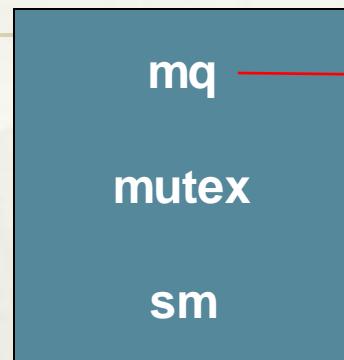
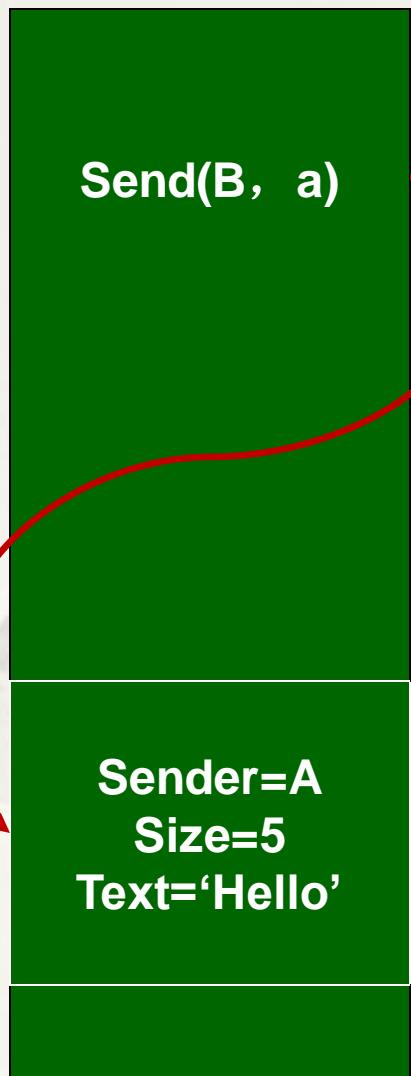
## (2) PCB中有关通信的数据项:

```
typedef struct processcontrol_block {  
    ...  
    struct message_buffer *mq ; //消息队列首指针  
    semaphore mutex; //消息队列互斥信号量  
    semaphore sm; //消息队列资源信号量  
} PCB;
```

进程A

PCB(B)

进程B



# 第七节 线程的基本概念

- \* 线程的基本概念
- \* 线程间的同步和通信
- \* 内核支持线程和用户级线程
- \* 线程控制

# 1、线程的基本概念

- 进程（60年代）
  - 目的
    - 使多个程序能够并发执行，提高资源利用率和系统吞吐量
  - 属性
    - OS中**拥有资源和独立运行**的基本单位
  - 局限性
    - 创建、撤消与切换时空开销大，限制了并发程度的提高
- 线程（80年代）
  - 目的
    - 减少并发时付出的时空开销，使系统具有更好的并发性
  - 基本思想
    - “轻装上阵”——将进程的两个属性分离
    - **线程—独立调度的基本单位，进程—拥有资源的单位**

## 2、线程的属性

### ① 轻型实体

- 线程几乎不占资源(TCB等)

### ② 独立调度的基本单位

- 切换迅速且开销小

### ③ 可并发执行

### ④ 共享进程的资源

- 同一进程内的线程共享进程的资源

### ⑤ 可以创建、撤销另一个线程

### 3、线程的状态

- \* 每个线程都利用TCB和一组状态参数进行描述
  - ① 状态参数
    - \* 寄存器状态、堆栈、运行状态、优先级...
  - ② 运行状态
    - \* 就绪状态、执行状态、阻塞状态

# 线程和进程的区别与联系

## \* 调度

- \* 线程是调度的基本单位
- \* 进程是资源拥有的基本单位

## \* 拥有资源

- \* 除必不可少的资源外，线程不拥有系统资源，但可以访问其隶属进程的系统资源，从而获得系统资源

## \* 并发性

- \* 支持多线程的OS中，不仅不同进程的线程之间可以并发，同一进程内的线程之间也可并发

## \* 系统开销

- \* 进程切换时的时空开销大
- \* 线程切换时，只需保存和设置少量信息，因此开销很小

## \* 支持多处理机系统

# 小结(1)

- \* 进程的概念和定义
- \* 前趋图如何画
- \* 进程的特征
- \* 进程的基本状态及转换
- \* PCB的作用
- \* 进程、程序的联系与区别

# 小结(2)

- \* 进程的创建、撤销、终止
- \* **进程同步、信号量、临界区、临界资源**
- \* 进程间高级通信方式
- \* **线程的概念**

# 练习题

1、临界区是指( D )

- A. 一块缓冲区
- B. 一段数据区
- C. 同步机制
- D. 一段程序

2、一个进程实体是( C )

- A. 由处理机执行的一个程序
- B. 一个独立的程序 + 数据集
- C. PCB + 程序 + 数据集
- D. 一个独立的程序

3、当( B )时, 进程由执行状态转为就绪状态

- A. 进程被调度程序选中
- B. 时间片到
- C. 等待某一事件
- D. 等待的事件发生

4、某进程在运行过程中需要等待从磁盘上读入数据, 此时该进程的状态将( )

- A. 从就绪变为执行
- B. 从执行变为就绪
- C. 从执行变为阻塞
- D. 从阻塞变为就绪

C

5、分配到必要的资源并获得处理机时的进程状态是( **B**

- A. 就绪状态      B. 执行状态
- C. 阻塞状态      D. 撤销状态

6、( **D**是一种只能进行 wait 操作和 signal 操作的特殊变量

- A. 调度    B. 进程    C. 同步    D. 信号量

7、进程控制块是描述进程状态和特性的数据结构，一个进程 (**D**)

- A. 可以有多个进程控制块
- B. 可以和其他进程共用一个进程控制块
- C. 可以没有进程控制块
- D. 只能有惟一的进程控制块

8、当已有进程进入临界区时，其他试图进入临界区的进程必须等待，以保证对临界资源的互斥访问，这是下列 (**B**) 同步机制准则

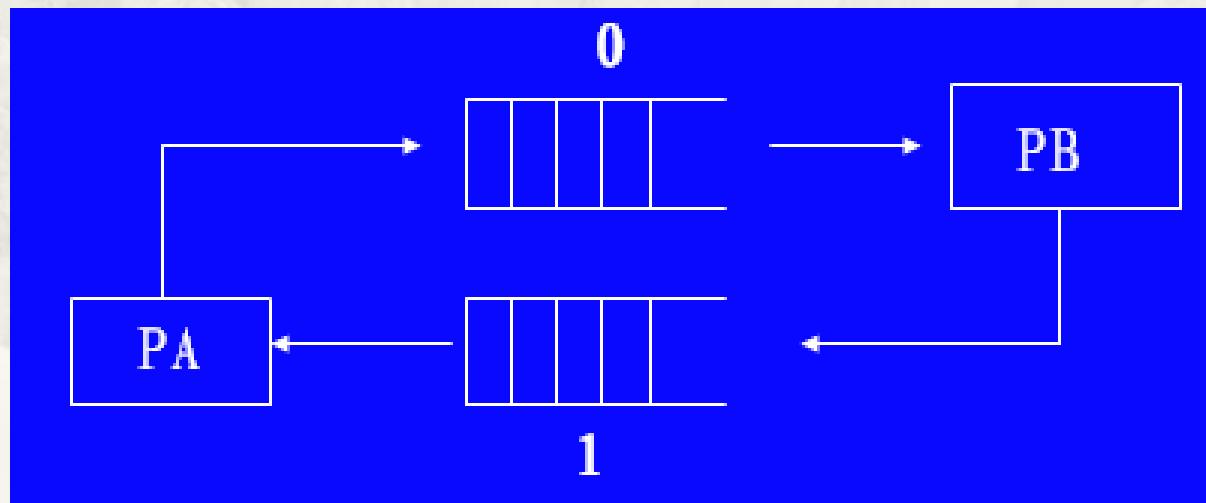
- A. 空闲让进
- B. 忙则等待
- C. 有限等待
- D. 让权等待

## 9、下面对临界区的论述中，正确的论述是 ( D )

- A. 临界区是指进程中用于实现进程互斥的那段代码
- B. 临界区是指进程中用于实现进程同步的那段代码
- C. 临界区是指进程中用于实现共享资源的那段代码
- D. 临界区是指进程中访问临界资源的那段代码

## 6、缓冲队列问题

- \* 两个进程 $P_A$ 、 $P_B$ 通过FIFO缓冲队列连接，每个缓冲区长度等于传送消息的长度， $P_A$ 、 $P_B$ 之间通信满足：
  - ① 当空缓冲区存在时，相应的发送进程才能发送消息
  - ② 当缓冲队列中至少存在一个非空缓冲区时，相应的进程才能接收一个消息
- \* 试描述发送函数 $send(l, m)$ 和接收函数 $receive(l, m)$ ;并用它俩实现两个进程的通信



- \* 定义数组buf[0], buf[1]； bufempty[0],buffull[1]是PA的私有信息量； bufempty[1],buffull[0]是PB的私有信息量。

初始时：

bufempty[0]=bufempty[1]=n, (n为缓冲队列中的缓冲区个数)  
buffull[0]=buffull[1]=0

void send (I, m)

{

wait (bufempty [ I ]);  
按FIFO方式选择一个  
空缓冲区buf[ I ] (x);  
buf[ I ](x) = m;  
buf[ I ](x)置满标志;  
signal(buffull [ I ]);

}

void receive (I, m)

{

wait (buffull [ I ]);  
按FIFO方式选择一个满  
数据的缓冲区buf[ I ] (x);  
m = buf[ I ](x) ;  
buf[ I ](x)置空标志;  
signal(bufempty [ I ]);

}

PA调用send (0, m)和receive (1, m)

PB调用send (1, m)和receive (0, m)